

DIRECTRICES DE LOS TRES NIVELES DE CONFIANZA

Agente HPR · Arquitectura de conocimiento, validación epistemológica y soberanía de ingesta

1. Propósito del documento

Este documento define las directrices para clasificar, evaluar y tratar la información obtenida por el agente HPR desde fuentes externas, especialmente la Web. Su finalidad es impedir que la disponibilidad de una fuente sea confundida con su confiabilidad o con su autorización para modificar el conocimiento operativo del sistema.

Estas directrices forman parte del marco experimental del Motor HPR y deberán utilizarse como referencia para futuras implementaciones de búsqueda, RAG local, validación de evidencia, entrenamiento y eventual generación de predicciones asociadas a la precarga conductual.

2. Principio rector

FUENTE ACCESIBLE ≠ FUENTE CONFIABLE ≠ CONOCIMIENTO AUTORIZADO

El agente puede encontrar información sin que ello implique que deba aceptarla como verdadera, incorporarla a su memoria o utilizarla para tomar decisiones. La clasificación de confianza es una capa previa a la autorización de ingesta.

3. Clasificación de confianza

Nivel	Factor de confianza	Fuentes representativas	Tratamiento
1 — Plena	FT = 1.0	Documentación oficial; estándares verificados	Documentación oficial o bitácora propia del HPR. Autorizado.
2 — Condicionada	FT = 0.5	Commits oficiales; documentación técnica reconocida	Requiere revisión académica antes de incorporarse como conocimiento.
3 — Exploratoria	FT = 0.1-0.3	Foros generales; blogs no institucionales; fuentes no verificadas	Información exploratoria/no verificada. No puede activar precondiciones.

4. Nivel 1 — Confianza plena

FT = 1.0

Comprende fuentes consideradas de máxima confiabilidad dentro del alcance definido por el proyecto: documentación oficial, estándares verificables y documentación o bitácora propia del HPR que haya sido establecida como referencia válida.

Regla operativa: puede tratarse como conocimiento validado, siempre que el contenido se encuentre dentro del dominio autorizado por la arquitectura y no contradiga una regla de seguridad superior.

Ejemplos: documentación oficial de una tecnología; especificación técnica reconocida; contrato o documentación interna del HPR; registro experimental aprobado por el proyecto.

5. Nivel 2 — Confianza condicionada

FT = 0.5

Incluye información técnicamente relevante que posee señales razonables de confiabilidad, pero que no debe convertirse automáticamente en conocimiento operativo. Requiere corroboración mediante una segunda fuente adecuada o mediante un procedimiento de revisión definido por el proyecto.

Regla operativa: no se incorpora de forma automática. Debe pasar por revisión cruzada, comprobación de coherencia y autorización de ingesta.

Ejemplos: commits oficiales; documentación técnica revisada; artículos académicos; material técnico que pueda ser contrastado con fuentes primarias.

6. Nivel 3 — Confianza exploratoria

FT = 0.1-0.3

Comprende información que puede ser útil para descubrir pistas, hipótesis o referencias, pero cuya garantía es insuficiente para convertirla en conocimiento operativo del agente.

Regla operativa: puede utilizarse para exploración y generación de pistas, pero no debe activar una modificación de conocimiento, una decisión crítica ni una precarga automática.

Ejemplos: foros generales, blogs no institucionales, comentarios o fuentes cuya procedencia y método de validación no estén suficientemente establecidos.

7. Flujo de tratamiento de información externa

ETAPA	ACCIÓN DEL AGENTE
1. Adquisición	Obtiene la información desde una fuente externa o desde un repositorio autorizado.
2. Identificación	Registra procedencia, tipo de fuente, fecha/contexto y contenido relevante.
3. Clasificación	Asigna Nivel 1, 2 o 3 y el correspondiente factor FT.
4. Evaluación	Determina si la información es coherente con el dominio y las reglas del sistema.
5. Corroboración	Para Nivel 2, busca evidencia adicional o revisión cruzada.
6. Soberanía de ingesta	SOVEREIGN-GATE determina si el contenido está autorizado para incorporarse.
7. Memoria operativa	Solo la información autorizada pasa a formar parte del conocimiento operativo.
8. Uso predictivo	Solo conocimiento elegible puede influir en procesos posteriores de decisión o predicción.

8. Integración con SOVEREIGN-GATE

La clasificación de confianza no sustituye al mecanismo de soberanía de ingesta. El factor FT funciona como una señal de confiabilidad de la fuente; SOVEREIGN-GATE decide si el conocimiento puede entrar al dominio operativo autorizado.

Principio: incluso una fuente de Nivel 1 no debe modificar parámetros protegidos, reglas de seguridad o conocimiento determinante sin cumplir las condiciones de autorización definidas por el sistema.

El Nivel 2 requiere corroboración antes de incorporarse. El Nivel 3 permanece en el ámbito exploratorio salvo que una posterior validación lo eleve mediante un procedimiento explícito.

9. Relación con NEXUS-ROOT y EPSILON-WALL

NEXUS-ROOT: protege el perímetro y bloquea intentos de suplantación, coerción o alteración del rol antes de que la información pueda afectar el flujo lógico.

EPSILON-WALL: determina si la solicitud o información se encuentra dentro del conocimiento y ámbito autorizado. Una fuente aparentemente confiable no habilita contenido fuera de dominio.

SOVEREIGN-GATE: controla la incorporación efectiva de información, parámetros o conocimiento al sistema.

10. Regla específica para la futura precarga conductual

La información utilizada por el agente para construir patrones, predicciones o decisiones que puedan alimentar el mecanismo de precarga conductual deberá proceder de conocimiento autorizado y trazable. La información exploratoria de Nivel 3 no deberá activar por sí misma una precarga automática.

La hipótesis experimental del HPR deberá mantenerse separada de la clasificación de fuentes: primero se determina qué conocimiento es admisible; posteriormente se evalúa si ese conocimiento permite anticipar estados, recursos o eventos con una ventaja medible.

11. Trazabilidad y registro

- Registrar la fuente y su procedencia.
- Registrar el nivel de confianza y el factor FT asignado.
- Registrar si hubo corroboración.
- Registrar la decisión de ingesta y su autorización.

- Mantener evidencia suficiente para reproducir por qué una pieza de información fue aceptada, condicionada o descartada.
- Separar conocimiento exploratorio de conocimiento operativo.

12. Reglas resumidas para implementación

1. El agente no debe equiparar disponibilidad con verdad.
2. El agente debe clasificar antes de incorporar.
3. Nivel 1 puede ser conocimiento validado dentro del alcance autorizado.
4. Nivel 2 requiere corroboración y autorización antes de convertirse en conocimiento operativo.
5. Nivel 3 es exploratorio y no debe activar precarga automática.
6. La clasificación de confianza no sustituye la autorización de SOVEREIGN-GATE.
7. Las reglas de seguridad y los parámetros determinantes permanecen bajo control administrativo.
8. Toda información que influya en procesos predictivos debe ser trazable.

13. Estado del documento

Documento base para la arquitectura experimental del agente HPR. Su contenido deberá evolucionar conforme se implementen los mecanismos reales de búsqueda, RAG local, evaluación de evidencia, memoria, autorización de ingesta y pruebas experimentales.

Nota metodológica: los factores FT son parámetros conceptuales iniciales para la arquitectura experimental; deberán ser sometidos a revisión y ajuste durante las pruebas del sistema. No constituyen por sí mismos una medida estadística de verdad.